

Trabalho-Prova (P1)

O Trabalho-Prova (P1) contém questões teóricas cujas respostas devem ser entregues, via Google Classroom, juntamente com os códigos da resolução prática de cada questão (as respostas podem ser apresentadas em um único arquivo Notebook Python).

1. (1.0 ponto) Encontre no Kaggle (<https://www.kaggle.com>) ou em outro repositório aberto alternativo uma base de dados com ao menos 1.000 instâncias (quanto maior, melhor) que possa ser explorada utilizando: (i) Métodos de Aprendizado de Máquina para **Classificação**, ou ainda (ii) Métodos de Aprendizado de Máquina para **Regressão**. Insira o link da base escolhida no arquivo público da turma postado no Classroom. Explicar os atributos de entrada, o atributo-meta (saída), e sua motivação para trabalhar com o problema de classificação (ou regressão) escolhido.
2. (6.0 pontos) Aplicar ao menos 03 algoritmos de Aprendizado de Máquina (AM) no conjunto de dados selecionado na Questão 1 (podem ser algoritmos vistos ou não estudados em sala de aula, à sua escolha). Siga as instruções:
 - a) Aplique as etapas necessárias de pré-processamento no *dataset* escolhido visando “preparar os dados” para o uso dos algoritmos de AM. Forneça detalhes dos processos de pré-processamento que utilizou.
 - b) Aplique os 03 (ou mais) algoritmos aos dados pós-processados. Sempre que pertinente, ajuste os hiperparâmetros a fim de melhor adequar os modelos aos dados e, conseqüentemente, aprimorar os resultados.
 - c) Se você optou por trabalhar com a aplicação de **Classificação**: (i) apresente os resultados obtidos utilizando ao menos 02 métricas quantitativas de avaliação; exiba também a Matriz de Confusão. (ii) Aplique alguma(s) ferramenta(s) de visualização (escolha livre) para analisar os dados. (iii) Compare os resultados obtidos pelos 03 (ou mais) algoritmos.
 - d) Se você optou por trabalhar com a aplicação de **Regressão**: (i) apresente os resultados obtidos utilizando ao menos 03 métricas quantitativas de avaliação, como o Mean Absolute Percentage Error (MAPE), Mean Absolute Error (MAE), Root Mean Square Error (RMSE), entre outras de sua escolha. (ii) Aplique alguma(s) ferramenta(s) de visualização (escolha livre) para analisar os dados. (iii) Compare os resultados obtidos pelos 03 (ou mais) algoritmos.
3. (3.0 pontos) A partir da base de dados *Breast Cancer Wisconsin*, disponível na biblioteca scikit-learn (função `load_breast_cancer`), responda:
 - a) Análise de Outliers: Utilize boxplots para analisar a presença de outliers em pelo menos 02 variáveis contínuas da base de dados. Esses outliers podem influenciar as previsões de modelos de aprendizado de máquina? Justifique.
 - b) Gere uma matriz de correlação entre os atributos da base de dados. Quais variáveis apresentam maior correlação entre si? Há indícios de multicolinearidade? Além disso, quais atributos parecem estar mais associados à variável alvo (diagnóstico)?
 - c) Algumas variáveis possuem escalas distintas. Escolha uma técnica de normalização (Min-Max Scaling ou Padronização) e aplique a pelo menos 03 variáveis. Explique como essa transformação pode impactar o desempenho de algoritmos de aprendizado de máquina.